

# Nichtlineare Optimierung - 2. Hausaufgabe

---

|                    |               |
|--------------------|---------------|
| Claudia Wohlgemuth | <i>366323</i> |
| Thorsten Lucke     | <i>363089</i> |
| Felix Thoma        | <i>358638</i> |

Tutor: Mathieu Rosière

17. Mai 2017

| 2.1 | 2.2 | 2.3 | 2.4 | $\Sigma$ |
|-----|-----|-----|-----|----------|
|     |     |     |     |          |

Anmerkungen:

## Aufgabe 2.1

---

Es sei  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  konvex und  $x \in \mathbb{R}^n$ . Für  $h \in \mathbb{R}^n$  bezeichne  $f'(x, h)$  die Richtungsableitung von  $f$  im Punkt  $x$  in Richtung  $h$  und weiter definieren wir

$$g_h : \mathbb{R} \rightarrow \mathbb{R}, \quad g_h(t) = f(x + th).$$

- (i) Sei  $h \in \mathbb{R}^n$  beliebig, aber fest gewählt. Mit der Konvexität von  $f$  folgt auch die Konvexität von  $g_h$ ; betrachte dazu für  $t_1, t_2 \in \mathbb{R}$ ,  $\lambda \in [0, 1]$

$$\begin{aligned} g_h(\lambda t_1 + (1 - \lambda)t_2) &= f((\lambda + (1 - \lambda))x + (\lambda t_1 + (1 - \lambda)t_2)h) \\ &= f(\lambda(x + t_1 h) + (1 - \lambda)(x + t_2 h)) \\ &\leq \lambda f(x + t_1 h) + (1 - \lambda)f(x + t_2 h) = \lambda g_h(t_1) + (1 - \lambda)g_h(t_2). \end{aligned}$$

Dann gilt für  $t, t_1, t_2 \in \mathbb{R}$  mit  $t_1 < t < t_2$  wie aus Analysis I bekannt

$$\frac{g(t) - g(t_1)}{t - t_1} \leq \frac{g(t_2) - g(t_1)}{t_2 - t_1} \leq \frac{g(t_2) - g(t)}{t_2 - t}.$$

Diese Ungleichung zeigt, dass der Differenzenquotient monoton wachsend ist (fixiere dazu jeweils  $t_1, t_2$  beziehungsweise  $t$ ). Damit ist insbesondere  $\frac{g(t) - g(0)}{t}$  für  $t \searrow 0$  monoton fallend und durch  $\frac{g(0) - g(-1)}{1}$  nach unten beschränkt. Somit existiert

$$\lim_{t \searrow 0} \frac{g(t) - g(0)}{t} = \lim_{t \searrow 0} \frac{f(x + th) - f(x)}{t} = f'(x, h).$$

- (ii) Sei  $h \in \mathbb{R}^n$  und  $\lambda > 0$ , dann gilt mit  $s = \lambda t$

$$\begin{aligned} f'(x, \lambda h) &= \lim_{t \rightarrow 0} \frac{f(x + t\lambda h) - f(x)}{t} = \lambda \lim_{t \rightarrow 0} \frac{f(x + t\lambda h) - f(x)}{\lambda t} \\ &= \lambda \lim_{s \rightarrow 0} \frac{f(x + sh) - f(x)}{s} = \lambda f'(x, h). \end{aligned}$$

- (iii) Seien  $h_1, h_2 \in \mathbb{R}^n$ . Mit (ii) gilt dann

$$\begin{aligned} f'(x, h_1 + h_2) &= \lim_{t \rightarrow 0} \frac{f(x + t(h_1 + h_2)) - f(x)}{t} \\ &= \lim_{t \rightarrow 0} \frac{f((\frac{1}{2} + \frac{1}{2})x + \frac{1}{2}2th_1 + \frac{1}{2}2th_2) - (\frac{1}{2} + \frac{1}{2})f(x)}{t} \\ &\leq \lim_{t \rightarrow 0} \frac{\frac{1}{2}f(x + 2th_1) - \frac{1}{2}f(x) + \frac{1}{2}f(x + 2th_2) - \frac{1}{2}f(x)}{t} \\ &= \frac{1}{2}f'(x, 2h_1) + \frac{1}{2}f'(x, 2h_2) \\ &= f'(x, h_1) + f'(x, h_2). \end{aligned}$$

- (iv) Als Gegenbeispiel untersuchen wir die euklidische Norm  $\|\cdot\| : \mathbb{R}^2 \rightarrow \mathbb{R}$  und ihre Richtungsableitung in Null. Dann ist

$$f'(0, e_1) = 1 \quad \text{und} \quad f'(0, e_2) = 1 \quad \text{sowie} \quad f'(0, e_1 + e_2) = \sqrt{2}.$$

## Aufgabe 2.2

---

Gegeben sei  $z \in \mathbb{R}^n$ . Wir untersuchen zu  $\lambda \geq 0$

$$f_\lambda: \mathbb{R}^n \rightarrow \mathbb{R}, \quad f_\lambda(x) = \frac{1}{2} \|x - z\|_2^2 + \lambda \|x\|_1 = \frac{1}{2} \sum_{k=1}^n |x_k - z_k|^2 + \lambda \sum_{k=1}^n |x_k|.$$

- (i) Wir zeigen, dass es für jedes  $\lambda \geq 0$  ein eindeutiges  $x_\lambda = \arg \min_{x \in \mathbb{R}^n} f_\lambda(x)$  gibt.

Sei also  $\lambda \geq 0$  beliebig. Wir zeigen, dass  $f_\lambda$  koerzitiv und streng konvex ist. Mit

$$f_\lambda(x) = \frac{1}{2} \|x - z\|_2^2 + \lambda \|x\|_1 \geq \frac{1}{2} \|x - z\|_2^2 \geq \|x\|_2^2 - \|x\|_2 \|z\|_2 + \|z\|_2^2 \geq \|x\|_2 (\|x\|_2 - \|z\|_2)$$

folgt die Koerzitivität von  $f_\lambda$ .

Außerdem ist  $f_\lambda$  Summe der streng konvexen Funktion  $n: x \mapsto \|x - z\|_2^2$  und der konvexen Funktion  $x \mapsto \|x\|_1$ . Bemerke dazu, dass  $n''(x) = \text{id}_{\mathbb{R}^n}$  positiv definit und  $n$  daher streng konvex ist und dass für alle  $x, y \in \mathbb{R}^n$  und  $t \in [0, 1]$  wegen der Dreiecksungleichung

$$\|tx + (1-t)y\|_1 \leq t\|x\|_1 + (1-t)\|y\|_1$$

gilt. Also ist  $f_\lambda$  selbst streng konvex und somit insbesondere stetig. Aus der Stetigkeit und Koerzitivität folgt, dass  $f_\lambda$  einen eindeutigen Minimierer  $x_\lambda$  besitzt.

- (ii)

## Aufgabe 2.3

---

Sei  $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$  linear und  $b \in \mathbb{R}^m$ . Wir betrachten die Abbildung  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  mit

$$f(x) = \frac{1}{2} \|Ax - b\|^2 = \frac{1}{2} \langle Ax - b, Ax - b \rangle = \frac{1}{2} (\langle A^T A x, x \rangle - 2 \langle A^T x, b \rangle + \langle b, b \rangle).$$

- (i) Dann ist die Ableitung in  $x \in \mathbb{R}^n$ , wie aus Analysis II bekannt, gegeben durch

$$f'(x) = A^T A x - A^T b$$

gegeben. Damit ergibt sich der Gradient

$$\nabla f(x) = f'(x)^T = x^T A^T A - b^T A^T.$$

- (ii) Ist  $\bar{x} \in \mathbb{R}^n$  ein Minimierer von  $f$ , dann ist insbesondere die notwendige Optimalitätsbedingung erfüllt, d.h. es gilt  $f'(\bar{x}) = 0$  und somit  $A^T A \bar{x} = A^T b$ . Wie aus Numerik bekannt, ist  $A^T A$  eine symmetrische, positiv semidefinite Matrix. Wegen  $f''(x) = A^T A$  für alle  $x \in \mathbb{R}^n$  ist  $f$  also konvex. Damit ist die Erfüllung der notwendigen Optimalitätsbedingung bereits hinreichend für Minimalität in einem Punkt.
- (iii) Nach (i) genügt es zu zeigen, dass  $A^T b \in \text{im } A^T A$  ist. Wir zeigen sogar  $\text{im } A^T = \text{im } A^T A$ . Dabei ist die Inklusion  $\text{im } A^T \supset \text{im } A^T A$  klar. Für  $x \in \mathbb{R}^n$  gilt weiterhin

$$\langle A^T A x, x \rangle = \langle A x, A x \rangle$$

Damit folgt aus  $x \in \ker A^T A$ , d.h.  $A^T A x = 0$ , dass

$$\|A x\|^2 = \langle A x, A x \rangle = \langle A^T A x, x \rangle = \langle 0, x \rangle = 0.$$

Also ist  $\|A x\| = 0$  und wegen der positiven Definitheit  $A x = 0$ , d.h.  $x \in \ker(A)$ . Umgekehrt folgt aus  $x \in \ker A$ , d.h.  $A x = 0$ , dass  $A^T A x = 0$ , d.h.  $x \in \ker A^T A$ . Also ist  $\ker A^T A = \ker A$  und  $\text{rank } A^T A = \text{rank } A = \text{rank } A^T$ . Daher muss bereits  $\text{im } A^T = \text{im } A^T A$  gelten, d.h. es gibt eine Lösung  $\bar{x} \in \mathbb{R}^n$  von  $A^T A \bar{x} = A^T b$ .

- (iv) Die quadratische Matrix  $A^T A \in \mathbb{R}^{n,n}$  hat wegen (iii) vollen Rang  $\text{rank } A^T A = \text{rank } A = n$  und ist somit invertierbar, d.h. die zugehörige Abbildung  $\mathbb{R}^n \rightarrow \mathbb{R}^n$  ist bijektiv. Folglich erfüllt nur  $x = (A^T A)^{-1} A^T b$  die notwendige Optimalitätsbedingung und ist nach (ii) einziger Minimierer.

## Aufgabe 2.4

Gegeben sei eine stetig differenzierbare Funktion  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  und ein Punkt  $\bar{x} \in \mathbb{R}^n$ . Für  $d \in \mathbb{R}^n$  definieren wir

$$g_d: \mathbb{R} \rightarrow \mathbb{R}, \quad g_d(t) = f(\bar{x} + td).$$

- (i) Sei  $f$  konvex und besitze für jedes  $d \in \mathbb{R}^n$  die Funktion  $g_d$  in  $\bar{x} \in \mathbb{R}$  ein lokales Minimum bei  $t = 0$ . Mit  $f$  ist auch  $g_d$  für  $d \in \mathbb{R}^n$  differenzierbar und mit der notwendigen Optimalitätsbedingung folgt

$$0 = g'_d(0) = \lim_{t \rightarrow 0} \frac{g_d(t) - g_d(0)}{t} = \lim_{t \rightarrow 0} \frac{f(\bar{x} + td) - f(\bar{x})}{t} = f'(\bar{x}, d).$$

Da  $f$  stetig differenzierbar ist, so ist die Ableitung in einem Punkt durch die partiellen Ableitungen gegeben. Insgesamt ist also  $f'(\bar{x}) = [f'(\bar{x}, e_1), \dots, f'(\bar{x}, e_n)] = 0$ . Zusammen mit der Konvexität folgt bereits, dass  $\bar{x}$  ein Minimierer von  $f$  ist.

- (ii) Wir betrachten die stetig differenzierbare Funktion

$$f: \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x, y) = (y - x^2)(y - 2x^2).$$

Für  $\bar{x} = 0$  und  $d = \begin{pmatrix} x \\ y \end{pmatrix} \in \mathbb{R}^2 \setminus \{0\}$  ist

$$g_d(t) = (ty - t^2x^2)(ty - 2t^2x^2).$$

Im Fall  $x = 0$  und  $y \neq 0$  gilt für  $t \neq 0$

$$g_d(t) = t^2y^2 > 0 = g_d(0)$$

Im Fall  $y = 0$  und  $x \neq 0$  gilt für  $t \neq 0$  analog

$$g_d(t) = 2t^4x^4 > 0 = g_d(0).$$

Im verbleibenden Fall  $x \neq 0$  und  $y \neq 0$  gilt für  $t < 0$

$$g_d(t) = (ty - t^2x^2)(ty - 2t^2x^2) = t^2(y - tx^2)(y - 2tx^2) > t^2y^2 > 0$$

und für  $t \in ]0, \frac{|y|}{2x^2}[$  wegen  $ty - t^2x^2 > 0$  und  $ty - 2t^2x^2 > 0$  schließlich ebenfalls

$$g_d(t) = (ty - t^2x^2)(ty - 2t^2x^2) = t^2(y - tx^2)(y - 2tx^2) > 0$$

Es gibt also stets eine punktierte Umgebung  $U$  um 0, so dass für alle  $t \in U$  gilt:

$$g_d(t) > 0 = g_d(0).$$

Daher ist  $t = 0$  für  $\bar{x} = 0$  und für jedes  $d \in \mathbb{R}^2 \setminus \{0\}$  ein lokaler Minimierer von  $g_d$ .

Allerdings ist  $f$  auf der Menge  $M = \{(x, y) \in \mathbb{R}^2 \setminus \{0\} \mid y = \frac{3}{2}x^2\}$  negativ:

$$f(x, y) = (y - x^2)(y - 2x^2) = \left(\frac{1}{2}x^2\right)\left(-\frac{1}{2}x^2\right) = -\frac{1}{4}x^4 < 0$$

Für alle  $r > 0$  gilt  $B_r(0) \cap M \neq \emptyset$ . Daher ist  $\bar{x} = 0$  kein lokaler Minimierer von  $f$ .